

Insper

Reinforcement Learning

Ana Beatriz Parra Ferreira

Maio de 2026

Atividade Prática Supervisionada (APS)

Este trabalho investiga a aplicação de Aprendizado por Reforço no problema de Coverage Path Planning (CPP) em ambientes discretos sob observabilidade parcial. O agente é treinado utilizando o algoritmo Proximal Policy Optimization (PPO), com uma representação de estado baseada em observações locais e um mapa global de células visitadas, além de uma função de recompensa projetada para incentivar a exploração eficiente.

Sumário

1 Contexto	1
1.1 Desafio do POMDP	1
2 Estratégia Implementada	1
2.1 Codificação do Estado e Invariância Espacial	1
2.2 Modelagem da Função de Recompensa (Reward Shaping)	2
2.3 Hiperparâmetros de Otimização	2
3 Resultados	3
3.1 Ambiente 5×5	3
3.2 Ambiente 10×10	5
3.3 Análise Comparativa	7
4 Propostas de Melhoria	7

1 Contexto

O problema de Coverage Path Planning (CPP) em ambientes dinâmicos ou desconhecidos representa um desafio central na robótica móvel, exigindo que um agente determine uma trajetória que visite todas as áreas livres de um mapa no menor tempo possível. No cenário proposto, a transição de um ambiente controlado de 5x5 para um de 10x10 revela a fragilidade da generalização em algoritmos de Aprendizado por Reforço (RL) quando o espaço de busca cresce exponencialmente. O fenômeno observado — onde o agente treinado em dimensões reduzidas fica "preso" em ambientes maiores — sugere que a política aprendida está excessivamente ajustada às coordenadas absolutas ou à densidade específica de obstáculos do treino original, falhando em abstrair o conceito lógico de "cobertura sistemática" para além de seus limites geográficos iniciais.

1.1 Desafio do POMDP

A complexidade é elevada pelo fato de o problema ser um Processo de Decisão de Markov Parcialmente Observável (POMDP). Ao contrário de um MDP clássico, onde o agente possui onisciência sobre o estado do mundo, o POMDP impõe que a tomada de decisão ocorra sob incerteza, baseando-se apenas em um mapa parcial e informações sensoriais locais. O desafio matemático reside na quebra da propriedade de Markov: a observação atual, isoladamente, não contém informação suficiente para determinar a ação ideal. Por exemplo, ao visualizar uma célula vazia à sua frente, o agente não consegue distinguir se aquela é uma área virgem ou uma área já visitada que ele está cruzando novamente, a menos que ele possua uma representação interna da história das observações. Sem essa memória, o agente sofre de "miopia cognitiva", o que explica os comportamentos cíclicos e a incapacidade de completar a cobertura em áreas que exigem planejamento de longo alcance.

2 Estratégia Implementada

A estratégia implementada baseia-se na transformação do problema de observabilidade parcial em um estado passível de generalização através de três frentes:

2.1 Codificação do Estado e Invariância Espacial

Para que o agente aprenda uma política $\pi(a|s)$ que não dependa de coordenadas fixas, a observação foi estruturada para fornecer contexto espacial relativo. O extrator de características utiliza Redes Neurais Convolucionais (CNNs) para processar o estado s_t , que é definido como:

$$s_t = \{O_{local}, M_{visited}, V_{agent}\}$$

Onde O_{local} representa a geometria local (obstáculos) e $M_{visited}$ representa o rastro histórico. A aplicação de filtros convolucionais permite que a rede aprenda a função de transição de forma invariante, identificando padrões de fronteira (áreas visitadas adjacentes a áreas não visitadas) independentemente da escala do grid (5×5 ou 10×10).

2.2 Modelagem da Função de Recompensa (Reward Shaping)

A função de recompensa $R(s, a, s')$ foi desenhada para mitigar o problema da esparsidade de recompensa em mapas maiores. O objetivo foi criar um gradiente de aprendizado que guie o agente mesmo antes de completar a cobertura total. A recompensa imediata é calculada por:

$$R_t = -0.15 + \mathbb{I}_{stayed} \cdot (-0.8) + \mathbb{I}_{new} \cdot 1.0 + \mathbb{I}_{frontier} \cdot 0.3 + \mathbb{I}_{revisit} \cdot (-0.5)$$

Além disso, quando ocorre cobertura total, o ambiente adiciona um bônus terminal de +10.0, e, quando o limite de passos é atingido sem cobertura completa, aplica uma penalidade terminal de -5.0.

Os parâmetros configurados no ambiente para estas variáveis são:

- $r_{new} = +1.0$: Recompensa por visitar uma célula inédita.
- $r_{frontier} = +0.3$: Bônus de fronteira, concedido se a nova célula expandir o limite do mapa conhecido.
- $r_{step} = -0.15$: Custo intrínseco de tempo para penalizar trajetórias ineficientes.
- $r_{revisit} = -0.5$: Penalidade por revisitação de áreas já exploradas.
- $r_{wall} = -0.8$: Penalidade por colisão com obstáculos ou tentativa de permanecer em uma posição inválida.
- $r_{goal} = +10.0$: Bônus por cobertura total.
- $r_{timeout} = -5.0$: Penalidade ao atingir o limite máximo de passos sem completar a cobertura.

Essa estrutura força o agente a maximizar o ganho acumulado

$$G_t = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1},$$

priorizando a exploração de áreas ainda não visitadas no mapa global.

2.3 Hiperparâmetros de Otimização

O treinamento utilizou o algoritmo PPO (Proximal Policy Optimization), que busca otimizar a política através de uma função objetivo clipada para garantir atualizações estáveis:

$$L^{CLIP}(\theta) = \mathbb{E}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right]$$

Os principais hiperparâmetros aplicados foram:

A arquitetura da policy foi configurada com um extrator de características baseado em CNN, com $cnn_out_dim = 128$, e com a rede final definida por $net_arch = \{\pi : [256, 256], vf : [256, 256]\}$.

Parâmetro	Símbolo	Valor	Função
Learning Rate	α	3×10^{-4}	Velocidade de ajuste dos pesos da rede
Discount Factor	γ	0.99	Importância dada a recompensas futuras (cobertura total)
Entropy Coef.	β	0.01	Incentiva a exploração ao evitar a convergência prematura
Number of Steps	n_steps	2048	Horizonte de coleta antes de cada atualização
Batch Size	N	256	Tamanho da amostra para cada atualização de gradiente
Clip Range	ϵ	0.2	Limite da razão de atualização da política

3 Resultados

A análise experimental foi conduzida em dois cenários distintos, correspondentes a ambientes de dimensões 5×5 e 10×10 . O objetivo foi avaliar não apenas a capacidade do agente de aprender uma política eficiente, mas principalmente sua habilidade de generalizar e completar a cobertura total sob condições de observabilidade parcial.

3.1 Ambiente 5×5




Figura 1: Evolução da entropia da política no ambiente 5×5 , indicando transição de exploração para comportamento mais determinístico ao longo do treinamento.




Figura 2: Curva de aprendizado no ambiente 5×5 , mostrando rápida convergência e estabilização do retorno médio por episódio.




Figura 3: Evolução da perda da função de valor no ambiente 5×5 , com tendência de estabilização após fase inicial de aprendizado.

Tabela 1: Resultados do experimento 5×5

Métrica	Valor
Taxa de Cobertura Total	94.00% (94/100)
Cobertura Média	$98.86\% \pm 6.47\%$
Cobertura Mínima	40.91%
Cobertura Máxima	100.00%
Passos Médios	42.0 ± 42.8
Passos Mínimos	21
Passos Máximos	200

Os resultados no ambiente 5×5 indicam que o agente consegue aprender uma política altamente eficiente, atingindo cobertura total na grande maioria dos episódios. A rápida convergência observada na curva de aprendizado, aliada à estabilização da função de valor, sugere que o problema, nesta escala, é suficientemente simples para que a política capture padrões de exploração eficazes mesmo sob observabilidade parcial.

3.2 Ambiente 10×10




Figura 4: Evolução da entropia no ambiente 10×10 , evidenciando regime instável de exploração ao longo do treinamento.




Figura 5: Curva de aprendizado no ambiente 10×10 , com aumento do retorno médio porém alta variabilidade.




Figura 6: Perda da função de valor no ambiente 10×10 , indicando instabilidade na estimativa de retornos futuros.

Tabela 2: Resultados do experimento 10×10

Métrica	Valor
Taxa de Cobertura Total	10.00% (10/100)
Cobertura Média	94.69% $\pm$ 12.67%
Cobertura Mínima	1.14%
Cobertura Máxima	100.00%
Passos Médios	387.2 $\pm$ 43.4
Passos Mínimos	191
Passos Máximos	400

No ambiente 10×10 , observa-se que, apesar da alta cobertura média, a taxa de sucesso é significativamente reduzida. Esse comportamento evidencia limitações da política em lidar com planejamento global sob observabilidade parcial, resultando em trajetórias redundantes e falha na cobertura completa.

3.3 Análise Comparativa

Em síntese, a comparação entre os ambientes 5×5 e 10×10 evidencia uma limitação estrutural da política aprendida quando submetida a escalas maiores. No cenário reduzido, o agente demonstra convergência estável, alta taxa de cobertura total e comportamento consistente. Entretanto, ao transpor para o ambiente 10×10 , observa-se uma dissociação entre desempenho médio e sucesso efetivo: embora a cobertura média permaneça elevada, a taxa de conclusão da tarefa é drasticamente reduzida.

Esse resultado sugere que o agente aprende estratégias localmente eficazes, mas falha em manter coerência global ao longo de episódios mais longos. A instabilidade observada na função de valor e a redução prematura da exploração contribuem diretamente para esse comportamento, levando o agente a entrar em ciclos e negligenciar regiões remanescentes do ambiente. Assim, o principal gargalo não está na ausência de aprendizado, mas na limitação de generalização e planejamento sob observabilidade parcial.

4 Propostas de Melhoria

Apesar do avanço no desempenho, a lacuna entre a cobertura média e a taxa de sucesso no ambiente 10×10 aponta para a necessidade de maior consistência temporal. Os resultados indicam que o agente é capaz de aprender padrões locais eficazes, mas ainda falha em manter coerência global ao longo de episódios mais longos. Nesse contexto, as seguintes evoluções são propostas:

- **Memória Recorrente (PPO-LSTM):** A inclusão de camadas LSTM permitiria ao agente codificar o histórico de decisões em um estado latente, facilitando a identificação de ciclos redundantes e o planejamento de longo prazo. Essa abordagem é particularmente relevante em ambientes POMDP, nos quais a observação atual não contém informação suficiente para decisões ótimas.

- **Motivação Intrínseca (Curiosidade):** A implementação de mecanismos de curiosidade, baseados no erro de predição da dinâmica do ambiente, incentivaria a exploração de regiões com alta incerteza. Esse tipo de sinal intrínseco é útil para guiar o agente em cenários onde a recompensa extrínseca é esparsa.
- **Curriculum Learning Granular:** A adoção de uma progressão incremental na complexidade dos ambientes (por exemplo, $5 \times 5 \rightarrow 7 \times 7 \rightarrow 10 \times 10$) pode reduzir a dificuldade de generalização. Esse processo suaviza a transição entre escalas e evita a estagnação em mínimos locais durante o treinamento.
- **Exploração Baseada em Fronteiras:** A incorporação explícita de informações geométricas relacionadas à fronteira entre regiões visitadas e não visitadas pode melhorar significativamente a eficiência da exploração. Técnicas como *Goal-conditioned Reinforcement Learning* podem ser utilizadas para direcionar o agente às áreas desconhecidas mais próximas.